

Analysis of Forearm Muscle Activation During Typing and Clicking Tasks in University Students

C. Ayala^{1,2}, N. Carrillo^{1,2}, A. Correa^{1,2}, A. Sánchez^{1,2}, A. Valer^{1,2}

¹Facultad de Ciencias e Ingeniería, Universidad Peruana Cayetano Heredia, Lima, Perú

²Facultad de Ciencias e Ingeniería, Pontificia Universidad Católica del Perú, Lima, Perú

Abstract—The increasing use of electronic devices in academic settings has led to a rise in musculoskeletal disorders (MSDs), particularly affecting the forearm muscles involved in repetitive activities such as typing and mouse use. Although the literature suggests that regular physical activity may have a protective effect against muscle fatigue, there is limited evidence linking an active lifestyle with forearm muscle activation during computer-related tasks. This study aims to compare the muscle activation of the forearm flexors and extensors—specifically the flexor digitorum superficialis and extensor digitorum—in physically active and sedentary university students using surface electromyography (sEMG) during typing and mouse-clicking tasks. The objective is to determine whether regular physical exercise contributes to greater tolerance to sustained digital device use by delaying the onset of muscle fatigue.

Index Terms—muscle fatigue, sEMG, clicks, mechanography, machine learning, signal processing

I. INTRODUCCIÓN

La digitalización ha incrementado el uso de dispositivos electrónicos en el ámbito educativo. Una revisión sistemática demostró que el 59,4% de los escolares (6–14 años) pasaban más de 2 horas diarias frente a dispositivos digitales luego del inicio de la pandemia [1]. Un estudio en el área de salud a residentes de 1, 2 y 3 años demostró que dedican más del 50% de su turno laboral al uso de computadoras [2].

Este incremento se puede evidenciar mayoritariamente en estudiantes universitarios, quienes usan la computadora como una herramienta de estudio y trabajo. En el 2011, una investigación indicó que el 90% de estudiantes universitarios contaban con una computadora personal [3]. Más recientemente, un estudio de la Universidad de California, Davis (2022) reportó que el 96,5% de los estudiantes posee una laptop, lo que evidencia un entorno educativo altamente digitalizado [4]. De manera complementaria, Carter et al. (2017) hallaron que el 86% de los estudiantes utiliza laptops durante las clases [5]. Además, centrándonos en el contexto del Perú, en el 2022, según el Instituto Nacional de Estadística e Informática (INEI), el 91% de los hogares poseen una computadora la cual utilizan con fines académicos o profesionales [6]. Este contexto implica un uso constante de actividades como la mecanografía y el clickeo del mouse.

Diversos estudios han vinculado el uso prolongado de computadoras con la aparición de trastornos musculoesqueléticos (TME). La fatiga muscular generada por los movimientos repetitivos de los dedos al usar el teclado, así como por la

postura sostenida al manipular el mouse, constituye un factor de riesgo [7]. Actividades rutinarias como la mecanografía y el uso del mouse (desplazamiento y clics repetitivos) provocan una activación sostenida de los músculos flexores y extensores del antebrazo, en particular del flexor digitorum superficialis y el extensor digitorum [8].

En este contexto, el estudio tiene como objetivo comparar la activación muscular de los flexores y extensores del antebrazo en estudiantes universitarios físicamente activos y sedentarios empleando electromiografía de superficie para medir la actividad muscular. Con ello, se espera aportar evidencia que relacione el estilo de vida activo con una mejor tolerancia al uso continuo de dispositivos digitales.

II. PLANTEAMIENTO DEL PROBLEMA

El uso de dispositivos electrónicos implica movimientos rápidos y repetitivos de los dedos y muñeca, la carga muscular estática y las posturas inadecuadas en un prolongado tiempo son factores de riesgo importantes para los TME relacionados con las computadoras que afectan principalmente al flexor digitorum superficialis y el extensor digitorum, músculos del antebrazo involucrados en actividades de mecanografía y uso del mouse. Diversos estudios sugieren que la práctica regular de actividad física podría desempeñar un rol protector frente a la fatiga y los trastornos musculoesqueléticos. Sin embargo, son escasos los estudios que analicen la actividad física con la activación muscular del antebrazo durante tareas de mecanografía y click en estudiantes.

III. PROPUESTA DE SOLUCIÓN

Frente a la poca información que existe actualmente, el presente estudio propone evaluar el efecto de la actividad física en la fatiga muscular del antebrazo dominante en estudiantes universitarios de entre 20 y 23 años mediante electromiografía de superficie (sEMG). Con el propósito de analizar si es que la realización de ejercicio constante ayuda a retrasar la aparición de la fatiga en comparación de individuos que no realizan actividad física, los individuos realizarán dos actividades (mecanografía y clicks con mouse) en un determinado lapso de tiempo.

IV. METODOLOGÍA

A. Adquisición de señales

1) **Participantes:** Se reclutaron voluntariamente 6 estudiantes entre 20 y 23 años de la Universidad Cayetano Heredia.

Se clasificó según el nivel de actividad física utilizando el Cuestionario Internacional de Actividad Física, que evalúa la frecuencia, duración e intensidad de la actividad física realizada en la última semana [9]. En base a dichos resultados, se dividieron en dos grupos: activos físicamente (categoría alta) y sedentarios (categoría baja), con 3 participantes por grupo. Se estableció como criterio de exclusión la presencia actual o pasada de lesiones musculoesqueléticas en el antebrazo.

2) **Materiales:** Se utilizaron dos placas BITalino (r)evolution Board Kit de la compañía Plux. Se empleó el canal analógico A1 de cada una, correspondiente a la entrada del sensor EMG. Según la hoja de datos se presenta una frecuencia de muestreo de 1000 Hz y un ancho de banda de 25 - 488 Hz [10]. La adquisición de la señal se realizó mediante Bluetooth entre las dos placas BITalino y dos computadoras que ejecutaron el software OpenSignals.

3) **Colocación de electrodos:** Las placas de bitalino fueron utilizadas para registrar la actividad de un músculo diferente (flexor digitorum superficialis y el extensor digitorum). Cada placa requería 3 electrodos desechables (positivo, negativo y referencia). La disposición de electrodos en el antebrazo se basó en el libro Anatomical Guide for the Electromyographer: The limbs and Trunk [11] y artículo de la Universidad Distrital Francisco José de Caldas [12], tal y como se observa en la Fig. 1.




Fig. 1. Ubicación de los electrodos en extensor digitorum (A) y flexor digitorum superficialis (B)

4) **Medición de señales:** Para la elección de los ejercicios, se tomó como referencia dos estudios previos [13], [14]. Se realizaron 4 ejercicios distintos con 2 minutos de descanso entre cada uno, los cuales se describen a continuación:

- Primer ejercicio: Se realizó una tarea de mecanografía durante 15 minutos utilizando la plataforma Keybr.
- Segundo ejercicio: Se realizó una actividad donde el sujeto debía clicar lo más rápido posible durante 5 minutos en la plataforma Cookie Clicker.
- Tercer ejercicio: Se realizó una actividad de clickeo por objetivos durante 5 minutos, con enfoque a clicks más precisos y dirigidos a objetivos visuales en la plataforma Mouse Accuracy.
- Cuarto ejercicio: Se realizó una actividad de clickeo por tiempos y ritmo durante 5 minutos en el videojuego Osu!.

Cabe resaltar que únicamente se registraron mediciones durante los primeros y últimos minutos de cada ejercicio. En

el caso del primer ejercicio, se obtuvieron mediciones durante 2 minutos al inicio y 2 minutos al final. Para los ejercicios posteriores las mediciones se limitaron a 1 minuto al inicio y 1 minuto al final de cada uno.

B. Preprocesamiento

El preprocesamiento de las señales se dividió en 2 etapas:

- En la primera etapa, debido a que las señales censadas por las placas BITalino fueron obtenidas en formato .h5, se utilizó el lenguaje de programación Python dentro del entorno de desarrollo Visual Studio Code para convertir las señales a CSV, realizar recortes en áreas de interés y eliminar segmentos sin actividad muscular.
- La segunda etapa se basó principalmente en la adición de una columna de tiempo relacionada con las ventanas de interés de los segmentos recortados de la señal en formato CSV.

C. Extracción de características

En este estudio, se extrajeron múltiples características a partir de las señales adquiridas, con el objetivo de representar su comportamiento, tendencia y variabilidad. Las características extraídas fueron las siguientes [15], [16]:

1) **Spectral power (Potencia espectral):** Mide la distribución de la energía de la señal EMG en bandas específicas (Hz). Permite identificar patrones de activación muscular, fatiga o presencia de artefactos. Durante una contracción la energía suele desplazarse de frecuencias altas a bajas. Las siete bandas analizadas fueron: [156,25 - 218,75] Hz, [93,75 - 156,25] Hz, [31,25 - 93,75] Hz, [406,25 - 468,75] Hz, [218,75 - 281,25] Hz, [468,75 - 531,25] Hz, [343,75 - 406,25] Hz.

2) **Spectral skewness (Asimetría espectral):** Mide la asimetría de la distribución espectral. Indica si la señal se concentra más hacia frecuencias bajas o altas.

3) **RMS (Root Mean Square):** Representa el valor cuadrático de la señal EMG y es una medida directa de la intensidad de la actividad muscular. Un incremento de RMS, debido a una mayor amplitud de la señal, representa una mayor activación muscular.

4) **Spectral kurtosis (Curtosis espectral):** Evalúa la desviación de la energía espectral en torno a la media.

5) **Skewness (Asimetría):** Mide la simetría de la forma de la señal en el dominio del tiempo. Es útil para comprobar si la energía fue mayor al principio o al final del movimiento.

6) **Kurtosis (Curtosis):** Indica la presencia de picos extremos o eventos de alta intensidad en la señal EMG.

D. Machine learning

Para el desarrollo de esta sección, se utilizó el software Edge Impulse para elaborar un modelo basado en redes neuronales convolucionales. El modelo fue diseñado para la clasificación binaria de la fatiga muscular en ejercicios de mecanografía y click. El programa optimiza el desarrollo de la arquitectura del modelo de redes neuronales a partir del preprocesamiento de las señales de EMG, se presenta el procedimiento dentro del programa:

1) **Creación de dataset:** Las señales EMG fueron subidas al dataset del Edge Impulse, se clasificaron las señales en 2 categorías: fatiga y sin_fatiga.

2) **Creación del impulso:** En la configuración del impulso, se especificó la entrada: Señal EMG, con un tamaño de ventana temporal de 1,000 ms y el tamaño de desplazamiento 10,000 ms. Se añadió el processing block de Spectral Analysis y el learning block de Classification con 2 output features: fatiga y sin_fatiga.

3) **Procesamiento de características espectrales:** Tras la creación del impulso, se debe realizar un ajuste automático de los parámetros, para poder filtrar con una frecuencia de corte del tipo alto y analizar la señal en el dominio de la frecuencia a partir de la transformada rápida de fourier con un tamaño de 16, se generaron características a partir de 87 ventanas de entrenamiento y 2 clases.

4) **Entrenamiento de la red neuronal:** Con los datos etiquetados se procedió al aprendizaje automático, donde el modelo aprende por épocas a detectar algoritmos. Edge Impulse diseñó la arquitectura de la red neuronal, teniendo como característica principal 1 salida correspondiente a la decisión del tipo de clase a la que corresponde la señal (fatiga o sin_fatiga). Se usó 120 ciclos de entrenamiento y un optimizador aprendido en vez de un hiper parámetro de tasa de aprendizaje Adam (Fig. 2).

Neural Network settings

Training settings

Number of training cycles ?

120

Use learned optimizer ?

☒

Training processor ?

GPU

Advanced training settings

Neural network architecture

Input layer (13 features)

Dense layer (20 neurons)

Dense layer (10 neurons)

Add an extra layer

Output layer (2 classes)

Fig. 2. Neural Network settings

E. Interfaz de usuario

La interfaz (Fig. 3) fue desarrollada utilizando Flutter y el entorno de desarrollo Visual Studio Code, mientras que el backend se implementará con FastAPI. La aplicación permitirá a los usuarios registrarse, cargar un archivo en formato .h5 y obtener las características extraídas de cada señal analizada.

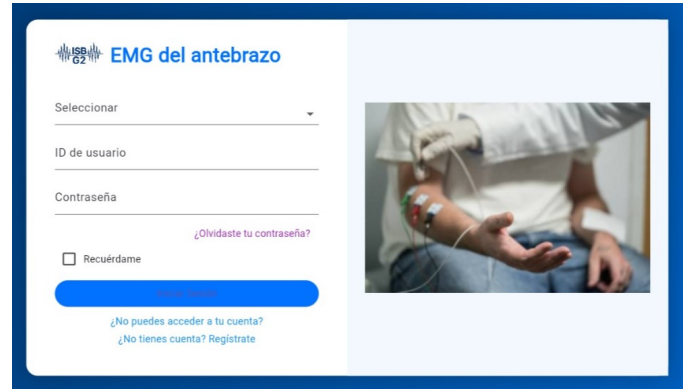


Fig. 3. Interfaz en Flutter

V. RESULTADOS

El modelo, dentro de las configuraciones presentadas para el entrenamiento automático de redes neuronales en clasificación binaria para la detección de fatiga alcanzó una precisión de 55.6% , como se observa en la Fig. 4, lo que indica que requiere más señales para aprendizaje automático y establecer mejores parámetros para un correcto aprendizaje y detección de características de las señales EMG de las clases “fatiga” y “no_fatiga”. En la gráfica de características se puede observar que las características extraídas de las 2 clases de señales están sobrepuestas, por lo que se debería considerar utilizar más capas ocultas dentro del diseño de la red neuronal y más neuronas por capa, así como aumentar el registro de señales.

El gráfico del Feature Explorer (Fig.5) muestra una distribución organizada de los datos correspondientes a las clases “fatiga” y “no_fatiga”, con una clara tendencia lineal que sugiere la presencia de una o dos características dominantes. Esta organización indica que las características extraídas, especialmente las espectrales, contienen información útil para discriminar entre ambos estados musculares. No obstante, se observa un solapamiento parcial entre las clases en la zona central del gráfico, lo cual puede generar confusión en el clasificador si no se optimiza la selección de características o el preprocesamiento de la señal EMG.

La importancia destacada de ciertas bandas de frecuencia, como las comprendidas entre 93,75 y 218,75 Hz, se evidencia en el análisis de importancia de características (Fig. 6) y respalda la relación entre fatiga muscular y cambios en el contenido espectral de la señal. Por ello, se recomienda enfocar el análisis en esas bandas relevantes y descartar características con baja contribución, como el skewness o kurtosis temporal. Además, aplicar un filtrado adecuado (por ejemplo, de 30 a 250 Hz) y ajustar el tamaño de las ventanas de análisis puede

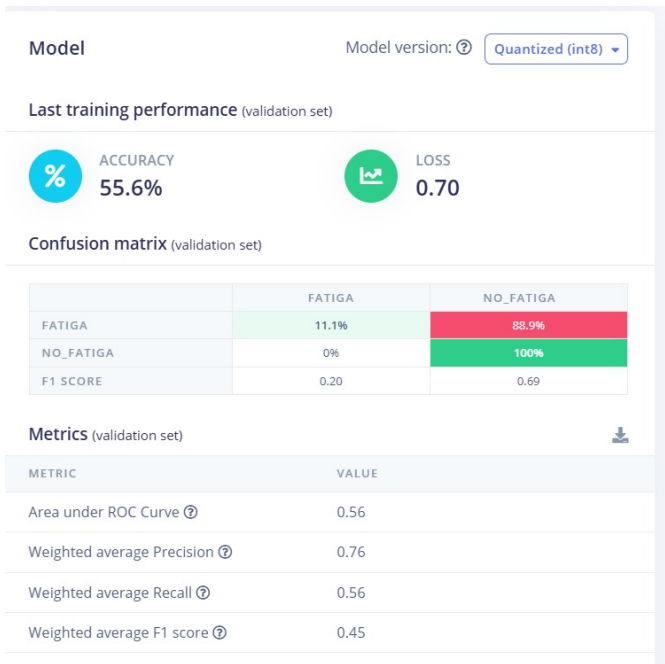


Fig. 4. Matriz de confusión del entrenamiento

ayudar a mejorar la separación entre clases y, con ello, el rendimiento del modelo de clasificación.

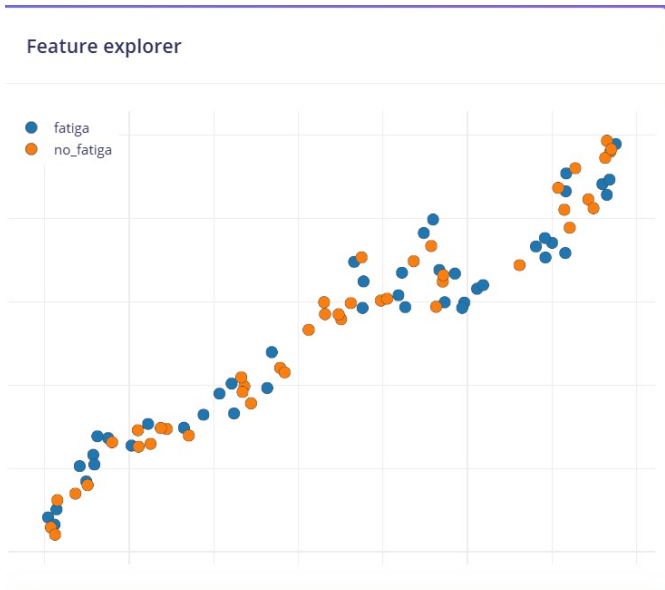


Fig. 5. Feature Explorer con distribución de las clases “fatiga” y “no_fatiga”

El gráfico del Data Explorer (Fig. 7) muestra la distribución de las ventanas de entrenamiento clasificadas como “fatiga” o “no_fatiga”, indicando con colores los aciertos y errores del modelo. La mayoría de los puntos verde limón y verde agua representan predicciones correctas, mientras que los puntos rojos y naranjas señalan errores de clasificación, los cuales se concentran principalmente en las zonas de transición entre ambas clases. Esta distribución confirma que el modelo



Fig. 6. Importancia relativa de las características extraídas de la señal EMG

tiene un rendimiento aceptable, pero presenta dificultades para discriminar entre clases cuando las señales comparten características similares, lo que sugiere la necesidad de optimizar el conjunto de características o el preprocesamiento de la señal EMG para mejorar la precisión.



Fig. 7. Data explorer

Durante la fase de prueba del modelo de red neuronal utilizado para la clasificación binaria de señales EMG en las clases “fatiga” y “no_fatiga”, se obtuvo una precisión del 45.00%, como se muestra en la Fig. 8. La matriz de confusión indica que ninguna de las muestras etiquetadas como

“fatiga” fue clasificada correctamente, mientras que el 60% de las muestras de la clase “no_fatiga” fueron correctamente identificadas. El restante fue clasificado como incierto.

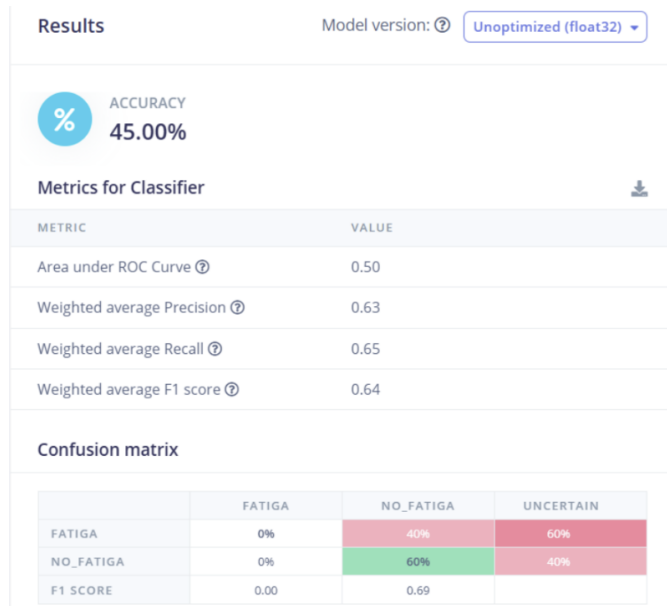


Fig. 8. Matriz de confusión de la etapa de prueba

VI. CONCLUSIONES

El modelo mostró un rendimiento limitado, con una precisión de entrenamiento del 55.6%, y una exactitud del 45% en la prueba, sin identificar correctamente los casos de fatiga. Aunque algunas bandas espectrales (93,75 - 218.75 Hz) fueron útiles, características como skewness y kurtosis temporales ofrecieron poca discriminación. El análisis de la matriz de confusión y del feature explorer evidenció solapamiento entre clases, lo que afectó la capacidad del modelo de distinguir los estados musculares.

Los resultados sugieren que no hubo una diferencia significativa en la activación muscular entre estudiantes sedentarios y activos físicamente. Inicialmente, se buscaba que el modelo de clasificación distinguiera entre ambos grupos en función de su nivel de actividad física. Sin embargo, al no encontrarse diferencias relevantes en las señales EMG, se optó por unificar a todos los participantes y enfocar el modelo únicamente en la detección de los estados de fatiga y no fatiga. Esto puede indicar que, en tareas digitales de corta duración como las evaluadas, el nivel de actividad física no tiene un efecto determinante sobre la fatiga muscular.

Este comportamiento puede atribuirse a distintas limitaciones del estudio. En primer lugar, el tamaño reducido de la muestra limitó la representatividad de los datos y la capacidad del modelo para generalizar patrones. Además, el tiempo de recuperación entre ejercicios fue insuficiente para aliviar la fatiga muscular acumulada. Asimismo, se observó que varios participantes no estaban familiarizados con la técnica correcta de mecanografía, en cuanto a la posición adecuada de las

manos sobre el teclado. Por último, se identificaron diferentes formas de agarre al momento de utilizar el mouse, lo que puede haber generado variabilidad en las señales registradas.

REFERENCES

- [1] J. Qi, Y. Yan, and H. Yin, "Screen time among school-aged children of aged 6–14: a systematic review," *Global Health Research and Policy*, vol. 8, no. 1, Apr. 2023, doi: <https://doi.org/10.1186/s41256-023-00297-z>.
- [2] L. Mamykina, D. K. Vawdrey, and G. Hripsak, "How Do Residents Spend Their Shift Time? A Time and Motion Study With a Particular Focus on the Use of Computers," *Academic Medicine*, vol. 91, no. 6, pp. 827–832, Apr. 2016, doi: <https://doi.org/10.1097/acm.0000000000001148>.
- [3] Dahlstrom, E., de Boer, T., Grunwald, P., and Vockley, M. (2011). The ECAR national study of undergraduate students and information technology, 2011 (Research Report). Boulder, CO: EDUCAUSE Center for Applied Research, October 2011. Available: <http://www.educause.edu/ecar>
- [4] UC Davis Campus Information Technologies and Educational Services, Student Computing Survey – Winter 2022, University of California, Davis, 2022. Available: <https://computerrooms.ucdavis.edu/pubs/survey/student-w2022.html>
- [5] S. P. Carter, K. Greenberg, and M. S. Walker, "The impact of computer usage on academic performance: Evidence from a randomized trial at the United States Military Academy," *Economics of Education Review*, vol. 56, pp. 118–132, Feb. 2017, doi: <https://doi.org/10.1016/j.econedurev.2016.12.005>.
- [6] Instituto Nacional de Estadística e Informática (INEI), Estadísticas de las Tecnologías de Información y Comunicación en los Hogares. Informe Técnico N.º 02, trimestre enero-febrero-marzo 2022, Lima, Perú, junio 2022.
- [7] J. H. Kim and P. W. Johnson, "Fatigue development in the finger flexor muscle differs between keyboard and mouse use," *European Journal of Applied Physiology*, vol. 114, no. 12, pp. 2469–2482, Aug. 2014, doi: <https://doi.org/10.1007/s00421-014-2974-y>.
- [8] M. S. Tremblay et al., "Systematic review of sedentary behaviour and health indicators in school-aged children and youth," *International Journal of Behavioral Nutrition and Physical Activity*, vol. 8, no. 1, pp. 98–98, Jan. 2011, doi: <https://doi.org/10.1186/1479-5868-8-98>.
- [9] R. Barrera, "Cuestionario Internacional de actividad física (IPAQ)," *Revista Enfermería del Trabajo*, vol. 7, no. 2, pp. 49–54, 2017, doi: <https://dialnet.unirioja.es/descarga/articulo/5920688.pdf>
- [10] PLUX – Wireless Biosignals S.A., Electromyography (EMG) Sensor User Manual, Nov. 2021. [Online]. Available: <https://support.pluxbiosignals.com/wp-content/uploads/2021/11/electromyography-emg-user-manual.pdf>
- [11] A. O. Perotto, *Anatomical Guide for the Electromyographer: The Limbs and Trunk*, 4th ed. Springfield, IL, USA: Charles C Thomas Publisher, 2005.
- [12] D. Reyes, M. López, J. Duarte y H. Loaiza-Correa, "Implementación en FPGA de un clasificador de movimientos de la mano usando señales EMG," *Redes de Ingeniería*, vol. 6, p. 85, sep. 2015. [Online]. Available: <https://doi.org/10.14483/udistrital.jour.redes.2015.1.a06>
- [13] M.-I. Lin, H.-W. Liang, K.-H. Lin, and Y.-H. Hwang, "Electromyographical assessment on muscular fatigue—an elaboration upon repetitive typing activity," *Journal of Electromyography and Kinesiology*, vol. 14, no. 6, pp. 661–669, Dec. 2004, doi: <https://doi.org/10.1016/j.jelekin.2004.03.004>
- [14] G. P. Y. Szeto and J. K. M. Lin, "A study of forearm muscle activity and wrist kinematics in symptomatic office workers performing mouse-clicking tasks with different precision and speed demands," *Journal of Electromyography and Kinesiology*, vol. 21, no. 1, pp. 59–66, Jul. 2010, doi: <https://doi.org/10.1016/j.jelekin.2010.06.006>. Available: <https://pubmed.ncbi.nlm.nih.gov/20643564/>.
- [15] Álvaro Costa-García, E. Iáñez, M. Yokoyama, S. Ueda, S. Okajima, and S. Shimoda, "Quantification of high and low sEMG spectral components during sustained isometric contraction," *Physiological Reports*, vol. 10, no. 10, May 2022, doi: <https://doi.org/10.14814/phy2.15296>.
- [16] J. M. Fajardo, O. Gomez, and F. Prieto, "EMG hand gesture classification using handcrafted and deep features," *Biomedical Signal Processing and Control*, vol. 63, p. 102210, Jan. 2021, doi: <https://doi.org/10.1016/j.bspc.2020.102210>.

VII. BIOGRAPHY OF AUTHORS

C. Ayala. is a 21-year-old biomedical engineering student at PUCP and UPCH, passionate about biomechanics, rehabilitation, and clinical engineering. He is a researcher at LIBRA PUCP and a member of IEEE EMBS. In 2024, he won first place in the II “Runayay Cayetano” Prototype Contest with a myoelectric prosthesis.

N. Carrillo. is a 22-year-old undergraduate student in Biomedical Engineering at Pontificia Universidad Católica del Perú (PUCP) and Universidad Peruana Cayetano Heredia (UPCH). She is a member of the IEEE EMBS and her areas of interest are tissue engineering and clinical engineering.

A. Correa is a 21-year-old undergraduate student in Biomedical Engineering at Pontificia Universidad Católica del Perú and Universidad Peruana Cayetano Heredia. A. is passionate about developing health technologies, with a strong focus on Clinical Engineering.

A. Sánchez is a 21-year-old undergraduate student in Biomedical Engineering at Pontificia Universidad Católica del Perú and Universidad Peruana Cayetano Heredia. He is driven by a strong interest in advancing medical solutions through innovations in biomaterials and tissue regeneration technologies.

A. Valer, 21 years old, is an undergraduate student in Biomedical Engineering at Universidad Peruana Cayetano Heredia, with interests in biomechanical rehabilitation and physiological signal processing.