# ANALYSIS OF FOREARM MUSCLE ACTIVATION DURING TYPING AND CLICKING TASKS IN UNIVERSITY STUDENTS

C. Ayala, N. Carrillo, A. Correa, A. Sánchez, A. Valer

## INTRODUCCIÓN A SEÑALES BIOMÉDICAS

## INTRODUCCIÓN



91% hogares tiene una computadora con fines académicos o laborales



En estudiantes universitarios:

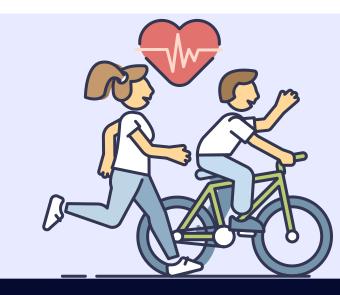
96.5% posee una laptop personal [1]

86% utiliza la laptop durante clases [2]

El uso intensivo de actividades repetitivas (mecanografía y clics) pueden generar fatiga muscular trastornos musculoesqueléticos (TME) [3]. La actividad física regular podría efecto tener un frente protector estos problemas [4].

#### PLANTEAMIENTO DEL PROBLEMA

La sobrecarga generada en los músculos por el uso prolongado de computadoras aumenta el riesgo de TME. Pocos estudios evalúan cómo la actividad física influye en la activación muscular en el antebrazo de los estudiantes.



## METODOLOGÍA

#### **PARTICIPANTES**

• 6 estudiantes entre 20 -23 años de UPCH, divididos en 2 categorías.

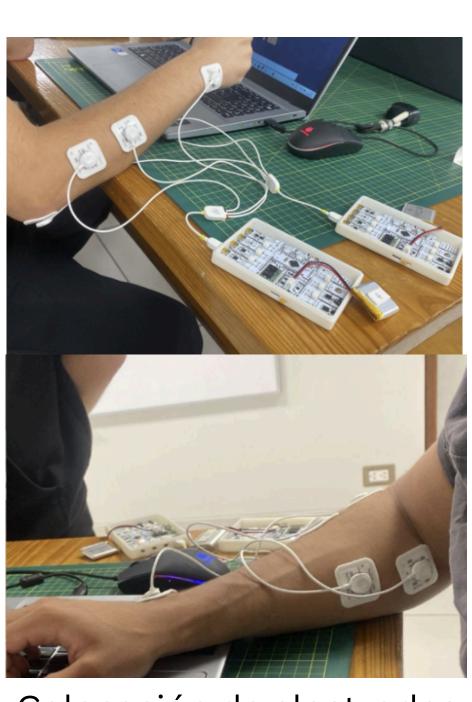


## Activos físicamente Sedentarios

Cuestionario IPAQ

## ADQUISICIÓN DE SEÑALES

- Dispositivo: 2 placas BITalino
- Software: OpenSignals
- Músculos:
  - Flexor digitorum superficialis
  - Extensor digitorum
- Actividades:
  - Mecanografía (15 min)
  - Clickeo rápido (5m)
  - Clickeo por objetivo (5min)
  - Clickeo rítmico (5min)



Colocación de electrodos

Results

45.00%

Metrics for Classifier

Area under ROC Curve 3

Weighted average Precision ②

Weighted average Recall ②

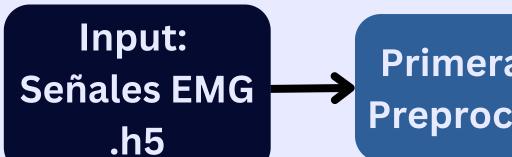
Confusion matrix

F1 SCORE

Weighted average F1 score 🔊

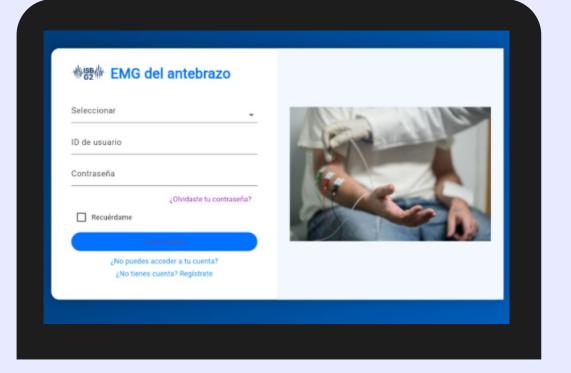
#### PROPUESTA DE SOLUCIÓN

Estudio comparativo del efecto de la actividad física en la activación muscular del antebrazo, utilizando electromiografía de superficie (sEMG) durante actividades rutinarias (mecanografía y clickeo), en estudiantes activos físicamente y sedentarios.



Primera etapa de Segunda etapa de Preprocesamiento Preprocesamiento

- Conversión de archivos .h5 a .csv (Python) tiempo
- Recorte de segmentos de interés
- Clasificación con Machine Learning
  - **Output:** Fatiga y no Fatiga
- Adición de una Plataforma: Edge Impulse columna de
  - Etiquetado de señales (fatiga / sin fatiga).
  - Entrenamiento: Red neuronal con 120 épocas



Model version: ② Unoptimized (float32) ▼

VALUE

0.50

0.63

0.65

0.64

0.00

60%

0.69

#### INTERFAZ DE USUARIO

App desarrollada en Flutter. Permite registrarse, cargar archivos .h5 y visualizar las características EMG extraídas.

#### RESULTADOS

#### Desempeño del modelo en entrenamiento y prueba Last training performance (validation set) ACCURACY 0.70 55.6% Confusion matrix (validation set) FATIGA NO\_FATIGA FATIGA 11.196 88.9% NO\_FATIGA

- Precisión en entrenamiento: 55.6 %
- Precisión en prueba: 45.0 %
- Las clases presentan solapamiento, lo que dificulta la clasificación.
- Bandas espectrales entre 93,75 y 218,75 Hz fueron las más relevantes.

#### CONCLUSIONES

- El modelo presentó un **rendimiento medio: 55.6% en** entrenamiento y 45% en prueba, sin detectar correctamente la fatiga.
- No se hallaron diferencias significativas en la actividad muscular entre estudiantes activos y sedentarios, por lo que se decidió unificar los grupos y enfocar el modelo solo en clasificar fatiga y no fatiga.
- En tareas digitales de corta duración, la actividad física no parece influir en la fatiga muscular.
- Limitaciones: Muestra reducida, poca recuperación entre ejercicios, técnica de mecanografía y agarre de mouse varían según el sujeto.